RAVENS

Ravener AI Vision for ENvironmental Surveillance

1. DATE DE IDENTIFICARE

- **Acronimul proiectului:** RAVENS
- **Categorie:** Seniori
- **Secțiune:** C – Tehnologia Informației
- **Mentorul echipei:** Domuț Bianca, Colegiul Național „Mihai Eminescu", nr. telefon:
- **Echipa de proiect:**
  - Mare Luca Ghiță, clasa a XI-a MI, Colegiul Național „Mihai Eminescu" - *Rol: Dezvoltator software principal & implementare inteligență artificială*
  - Barbu Brigitta-Barbara, clasa a XI-a MI, Colegiul Național „Mihai Eminescu" - *Rol: Cercetare, documentare & testare*
- **Colaboratori:**
  - Zubac Radu - Inginerie și Proiectare 3D
  - Pintilie Radu - Inginerie și Ecologie

2. REZUMATUL PROIECTULUI

RAVENS (*Ravener AI Vision for ENvironmental Surveillance*) este o aplicație software, concepută pentru monitorizarea și protecția mediului înconjurător, cu accent pe combaterea poluării fluviale și a deversărilor ilegale.

Aplicația prelucrează datele senzoriale furnizate de modulul Ravener, hărți 3D generate prin tehnologie LiDAR, imagini optice 4K și date termice, pentru a identifica, clasifica și urmări deșeurile și poluanții din mediul acvatic și riveran.

Funcționalitățile principale ale aplicației sunt: **cartografierea și clasificarea deșeurilor** detectate prin LiDAR, cu predicții ale traseului generate prin inteligență artificială, folosind date hidrologice de la surse publice (ANAR); **detectarea deversărilor ilegale** prin coroborarea datelor LiDAR cu camerele optică și termică, cu clasificarea substanțelor și generarea de statistici predictive AI; **calcularea probabilității de poluare** și identificarea zonelor cu risc ridicat; **raportare civică** prin fotografiere, cu validare automată AI și integrare în baza de date; **analiză localizată a calității apelor** pentru utilizatori specifici (fermieri, autorități locale); și un **chatbot specializat** în ecologie și protecția mediului.

Prin integrarea algoritmilor avansați de machine learning cu date geospațiale în timp real, RAVENS transformă observația statică în monitorizare predictivă, oferind autorităților și comunităților instrumente concrete de acțiune împotriva poluării.

3. DESCRIEREA DETALIATĂ A PROIECTULUI

Scopul proiectului

Scopul proiectului RAVENS este dezvoltarea unei aplicații software inteligente, capabile să proceseze și să interpreteze date multi-senzoriale, LiDAR, optice și termice, în vederea monitorizării automate a poluării mediului acvatic și riveran.

Aplicația urmărește să transforme datele brute de scanare în informații acționabile: hărți interactive de poluare, clasificări ale deșeurilor și substanțelor periculoase, predicții ale dispersiei poluanților și alerte în timp real pentru autorități și comunități. Prin integrarea algoritmilor de machine learning cu surse de date hidrologice publice (ANAR), RAVENS depășește paradigma monitorizării reactive, instaurând o abordare predictivă și preventivă în protecția mediului.

Proiectul se adresează deopotrivă autorităților de mediu, administrațiilor locale, fermierilor și cetățenilor, oferind un ecosistem digital complet, de la detecție automată, până la raportare civică și consultanță ecologică prin chatbot specializat.

Obiectivele proiectului

O1. Proiectarea și implementarea unui modul de procesare a norilor de puncte 3D generați prin tehnologie LiDAR, capabil să detecteze și să clasifice automat deșeurile solide din mediul acvatic și riveran.

O2. Dezvoltarea unui sistem de detectare a deversărilor ilegale prin coroborarea datelor LiDAR cu imagistica optică 4K și termică, bazat pe analiza anomaliilor de temperatură și pe clasificarea spectrală a substanțelor.

O3. Implementarea unui modul AI de predicție a traseului deșeurilor și poluanților, prin integrarea datelor hidrologice în timp real (debit, traseu, viteza curentului) furnizate de surse publice, precum ANAR.

O4. Crearea unui sistem de cartografiere interactivă care să vizualizeze în timp real localizarea deșeurilor, a deversărilor și a zonelor cu risc ridicat de poluare, cu actualizare continuă a bazei de date.

O5. Implementarea unui modul de raportare civică prin care cetățenii pot fotografia zone poluate, fotografia fiind supusă validării automate prin inteligență artificială înainte de înregistrarea în sistem.

O6. Dezvoltarea unui modul de analiză localizată a calității apelor, adaptat nevoilor specifice ale diferitelor categorii de utilizatori (fermieri, autorități, populație generală).

O7. Integrarea unui chatbot specializat în ecologie și protecția mediului, capabil să ofere recomandări personalizate și să educe utilizatorii cu privire la acțiuni sustenabile.

Problema identificată spre rezolvare și stadiul actual în domeniu

3.1. Contextul problemei

Poluarea mediului acvatic reprezintă una dintre cele mai grave provocări de mediu ale secolului XXI. România se confruntă cu o situație îngrijorătoare în acest sens: bazinele hidrografice ale râurilor Someș, Mureș, Olt și Siret sunt afectate periodic de deversări industriale ilegale, depozitări necontrolate de deșeuri pe maluri și acumulări masive de detritus plastic transportat de curenți. Conform rapoartelor Administrației Naționale Apele Române (ANAR), sute de incidente de poluare sunt înregistrate anual, însă numărul real este estimat a fi semnificativ mai mare, dată fiind capacitatea limitată de monitorizare a autorităților.

Problema se manifestă pe două planuri principale, cărora RAVENS le răspunde direct:

Depozitarea ilegală a deșeurilor pe malurile cursurilor de apă și în albiile acestora generează contaminare progresivă a solului și a pânzei freatice, fragmentare a habitatelor acvatice și acumulare de microplastice în lanțul trofic. Deșeurile solide transportate de curenți pot parcurge sute de kilometri, afectând ecosisteme îndepărtate de sursa poluării, fapt care face extrem de dificilă identificarea și sancționarea responsabililor.

Deversările ilegale de substanțe (ape uzate industriale, hidrocarburi, substanțe chimice) reprezintă o amenințare acută, adesea cu efecte ireversibile asupra biodiversității acvatice. Aceste deversări sunt frecvent camuflate sau realizate în zone inaccesibile, noaptea sau în perioade de debit ridicat, tocmai pentru a eluda controalele autorităților.

3.2. Limitele soluțiilor existente

Metodele actuale de monitorizare prezintă limitări structurale care justifică RAVENS: monitorizarea manuală este lentă și acoperă suprafețe limitate; stațiile fixe ANAR oferă date punctuale și nu detectează surse mobile sau intermitente; teledetecția satelitară (Sentinel-2, Landsat) are rezoluție insuficientă pentru deșeuri mici sau conducte îngropate și frecvență de revizie de câteva zile; aplicațiile civice (ex. Sesizează.ro) se bazează pe contribuții manuale, fără validare automată sau capacitate predictivă.

3.3. Stadiul actual al tehnologiilor relevante

Fiecare tehnologie integrată în RAVENS este validată individual în literatura de specialitate — LiDAR pentru cartografierea mediului (Remote Sensing MDPI, ISPRS Journal of Photogrammetry), imagistica termică delta-T pentru deversări industriale (NASA Earth Observatory), CNN și YOLO pentru clasificarea materialelor aeriene, modele hidrologice AI pentru predicția traseului poluanților (WASP, US EPA). Originalitatea RAVENS constă în integrarea tuturor acestora într-un ecosistem software unitar, inexistent la nivel național.

Etapele parcurse

Etapa 1 – Documentare și fundamentare științifică Echipa a studiat principiile LiDAR și procesarea norilor de puncte 3D (ISPRS Journal of Photogrammetry, Remote Sensing MDPI), metodele de teledetecție termică validate de NASA și arhitecturile ML pentru detectarea

materialelor aeriene (YOLO v8, CNN). Au fost analizate rapoartele ANAR și aplicațiile civice existente pentru formularea cerințelor funcționale ale RAVENS.

Etapa 2 – Definirea conceptului și arhitecturii sistemului A fost definită arhitectura software pe șase module funcționale independente, diagrama de flux date (input senzorial → hărți, alerte, predicții) și schema bazei de date relaționale pentru istoricul spațio-temporal al incidentelor. Tehnologii selectate: Python, React Native, PostgreSQL + PostGIS, FastAPI.

Etapa 3 – Proiectare tehnică și prototipare Mare Luca Ghiță a implementat pipeline-ul LiDAR (Open3D: SOR → DBSCAN → extragere caracteristici). A fost antrenat un model CNN pe SensatUrban + ISPRS Vaihingen Benchmark, augmentat cu date sintetice, obținând 87% precizie pe setul de validare. CNN a fost ales față de Random Forest și SVM prin performanță superioară pe date aeriene multi-spectrale.

Etapa 4 – Implementare experimentală Au fost integrate toate modulele: cartografiere interactivă (Leaflet.js + GeoJSON), detecție deversări, predicție traseu (API ANAR), raportare civică cu validare AI și chatbot LLM fine-tuned pe legislație de mediu și ecologie. Interfața mobilă a fost prototipată — flux raportare sub 30 de secunde.

Etapa 5 – Evaluare și validare Pipeline-ul LiDAR testat pe date publice: rată detecție 91%, fals-pozitiv 6%. Modulul termic validat pe date sintetice calibrate NASA: detecție anomalii $\Delta T \geq 2°C$ față de temperatura de fond.

Etapa 6 – Diseminare și impact social Proiectul a fost prezentat comunității școlare și unui dialog inițiat cu Garda de Mediu privind integrarea modulului civic. Codul sursă este pregătit pentru publicare open-source.

Metode folosite și descrierea sistemelor realizate

1. Metodologia generală

Proiectul RAVENS a fost dezvoltat printr-o abordare interdisciplinară, combinând metode de cercetare științifică (observație, analiză comparativă, validare experimentală), metode inginerești (proiectare software, prototipare, testare) și metode digitale (modelare AI, procesare geospațială, simulări). Arhitectura aplicației urmează paradigma pipeline-ului modular de procesare a datelor, în care fiecare modul îndeplinește o funcție bine delimitată, comunică prin interfețe standardizate și poate fi actualizat independent fără a afecta restul sistemului.

2. Descrierea sistemelor realizate

2.1. Pipeline-ul de procesare LiDAR și clasificarea deșeurilor

Nucleul tehnic al RAVENS îl constituie pipeline-ul de procesare a norilor de puncte 3D (format LAS/LAZ) generați de senzorul LiDAR al modulului Ravener, structurat în patru etape:

Preprocesare: Algoritmul Statistical Outlier Removal (SOR) elimină punctele aberante pe baza distanței față de cei k vecini apropiați, reducând volumul de date cu 8–12% și crescând acuratețea segmentării.

Segmentare: DBSCAN grupează punctele pe baza densității spațiale locale, fără a necesita numărul de clustere predefinit. A fost preferat față de k-means datorită capacității de a detecta forme arbitrare — esențială pentru geometria neregulată a deșeurilor.

Extragerea caracteristicilor: Per cluster se calculează: volumul bounding box-ului orientat (OBB), înălțimea față de planul terenului, densitatea punctelor și indicii de sfericititate și planaritate — vectorul de features al clasificatorului.

Clasificarea: Un model CNN clasifică fiecare obiect în: plastic, metal, deșeuri organice, materiale de construcție, substanțe lichide sau fond. Modelul fuzionează caracteristicile LiDAR cu textura/culoarea din imaginea optică 4K coregistrată (*point cloud colorization*), obținând o creștere de 14 puncte procentuale față de LiDAR exclusiv.

2.2. Sistemul de detectare a deversărilor ilegale

Detectarea deversărilor ilegale utilizează o abordare prin fuziune senzorială pe trei niveluri, care combină datele LiDAR, camera optică și camera termică într-un sistem de decizie unificat:

Analiza termică — detecția anomaliilor delta-T: Camera termică furnizează o hartă de temperatură a suprafeței apei și a terenului adiacent. Algoritmul de detecție identifică zone cu variații de temperatură semnificative față de temperatura de fond — pragul de detecție este setat la $\Delta T \geq 2°C$, conform parametrilor documentați în literatura NASA pentru deversările industriale calde. Zonele cu anomalii termice sunt marcate ca regiuni de interes (ROI — Regions of Interest) și transmise etapelor ulterioare de analiză.

Analiza optică — clasificarea substanțelor: În cadrul ROI-urilor identificate termic, imaginile optice 4K sunt analizate printr-un model de segmentare semantică bazat pe arhitectura DeepLab v3+, care clasifică pixelii în funcție de caracteristicile spectrale: apă curată, hidrocarbon/ulei (irizație caracteristică), spumă industrială, sediment în suspensie sau substanță de culoare atipică. Această etapă permite distincția între deversările accidentale de hidrocarburi, deversările de ape uzate industriale și turbiditatea naturală.

Confirmarea prin LiDAR — detecția infrastructurii ascunse: Norul de puncte 3D este analizat pentru identificarea elementelor artificiale îngropate sau camuflate în vegetație — conducte, supape de by-pass, structuri de beton neautorizate. Algoritmul de detecție a planelor și cilindrilor prin RANSAC (Random Sample Consensus) extrage primitive geometrice regulate

din norul de puncte, incompatibile cu morfologia naturală a terenului, semnalând potențiale instalații ilegale de deversare.

Decizia finală de clasificare a unui incident ca deversare ilegală este luată de un clasificator ensemble care ponderează scorurile celor trei surse senzoriale, reducând rata de fals-pozitiv la 6% în testele de validare.

2.3. Modulul AI de predicție a traseului poluanților

Modulul integrează trei categorii de date pentru a calcula distribuția probabilistică a poziției unui poluant la 1, 6, 12 și 24 de ore de la detecție:

Date hidrologice în timp real (API ANAR): debit instantaneu, viteza curentului, cota nivelului apei și traseul vectorial al rețelei hidrografice.

Date geospațiale statice: MDE extras din datele LiDAR cumulate ale misiunilor anterioare, cu rezoluție de 0.5m — superior față de sursele publice (SRTM 30m, ALOS 12.5m).

Modelul de transport: Un model de advecție-difuzie calibrat pe parametrii ANAR, augmentat cu un strat de corecție LSTM. Rețeaua recurentă învață comportamentul specific al fiecărui segment de râu din istoricul incidentelor — zone de acumulare, debite sezoniere atipice — reducând eroarea de predicție la 6 ore cu 18% față de modelul hidraulic pur.

Rezultatul este vizualizat pe harta interactivă ca un con de probabilitate animat, cu intensitate cromatică proporțională cu densitatea probabilistică a prezenței poluantului.

2.4. Sistemul de cartografiere interactivă și baza de date

Toate evenimentele detectate — deșeuri, deversări, zone de risc — sunt înregistrate în timp real într-o bază de date PostgreSQL cu extensia PostGIS, care oferă suport nativ pentru tipuri de date geospațiale și interogări spațiale eficiente (intersecții, buffere, agregări pe poligoane administrative).

Interfața de cartografiere este construită pe Leaflet.js, cu straturi tematice comutabile: stratul deșeurilor (clasificate cromato după tip), stratul deversărilor (cu indicatori de severitate), stratul zonelor de risc (heatmap probabilistic) și stratul predicțiilor de traseu. Utilizatorii autorizați (autorități, inspectori) au acces la un panou de administrare care permite exportul rapoartelor în format PDF și GeoJSON, filtrarea istorică a incidentelor și gestionarea alertelor automate prin email/SMS.

2.5. Modulul de raportare civică cu validare AI

Utilizatorii aplicației mobile fotografiază zone suspecte de poluare, imaginea fiind procesată automat de un clasificator binar antrenat pe un dataset echilibrat (poluare confirmată vs. teren curat). Sesizările cu scor de certitudine peste pragul de 0.75 sunt înregistrate în baza de date și marcate pe hartă ca incidente neconfirmate, vizibile inspectorilor de mediu. Cele sub prag sunt returnate cu un mesaj explicativ, menținând integritatea bazei de date.

2.6. Modulul de analiză a calității apelor

Pe baza datelor cumulate și a informațiilor hidrologice ANAR, modulul generează rapoarte personalizate per tronson de curs de apă. Fermierii primesc indicatori relevanți pentru irigații (sedimente, hidrocarburi, substanțe chimice în amonte), iar autoritățile locale primesc rapoarte agregate cu indicele de risc calculat per tronson administrativ, pe baza frecvenței și severității incidentelor.

2.7. Chatbot-ul specializat în ecologie

Chatbot-ul este implementat pe un LLM ajustat fin pe un corpus specializat: legislație de mediu românească (Legea apelor nr. 107/1996, OUG 195/2005), ghiduri agricole sustenabile și materiale de ecologie acvatică. Utilizatorii pot obține în limbă naturală sfaturi de mediu, explicații ale indicatorilor de calitate a apei sau procedura de sesizare a unei deversări ilegale.

Date experimentale și detalii esențiale ale experimentelor

1. Experimentul 1 — Validarea pipeline-ului de procesare LiDAR și clasificarea deșeurilor

Pentru validarea modulului de procesare LiDAR, echipa a utilizat seturi de date publice de referință, în absența posibilității de zbor operațional cu modulul Ravener în faza de prototipare software. Au fost utilizate două surse principale: datasetul **SensatUrban** (Birmingham & Cambridge, UK), care conține noruri de puncte LiDAR aeriene dense cu adnotări semantice, și datasetul **ISPRS Vaihingen Benchmark**, standard internațional pentru evaluarea algoritmilor de clasificare a norilor de puncte.

Datele au fost augmentate cu scenarii sintetice de depozitare ilegală, generate prin inserarea manuală de clustere de puncte cu caracteristici geometrice specifice deșeurilor solide — volum redus, geometrie neregulată, înălțime variabilă față de planul terenului — în norurile de puncte originale, simulând condiții reale de depozitare pe maluri de râu.

Categorie deșeu	**Precizie**	**Recall**	**F1-Score**	**F1-Score**
Plastic	89%	86%	87%	87%
Metal	91%	88%	89%	89%
Deșeuri organice	83%	80%	81%	81%
Materiale construcții	92%	90%	91%	91%
Substanțe lichide	86%	84%	85%	85%
Medie ponderată	**88%**	**86%**	**87%**	**87%**

Rata globală de detecție a obiectelor (indiferent de categorie) a fost de **91%**, cu o rată de fals-pozitiv de **6%**, reprezentată preponderent de elemente naturale cu geometrie similară deșeurilor — trunchiuri căzute, pietre de dimensiuni medii.

Timpul de procesare al unui nor de puncte de 1 milion de puncte (corespunzător unei zone de aproximativ 200×200 metri la rezoluție operațională) a fost de **4.2 secunde** pe hardware de nivel mediu (CPU Intel Core i7, 16GB RAM), confirming fezabilitatea procesării în timp cvasi-real în cadrul sesiunilor de zbor.

2. Experimentul 2 — Validarea detecției anomaliilor termice

Validarea modulului de detecție termică a fost realizată pe un dataset sintetic calibrat, construit conform parametrilor delta-T documentați în literatura NASA pentru deversările industriale. Au fost simulate trei scenarii de deversare:

Scenariul A — Deversare caldă (efluent industrial): Temperatura deversării simulată la +8°C față de temperatura apei receptoare. Rată de detecție: **97%**.

Scenariul B — Deversare la temperatură moderată: $\Delta T = 3°C$ față de temperatura de fond. Rată de detecție: **89%**.

Scenariul C — Deversare cu contrast termic redus: $\Delta T = 2°C$, la limita pragului de detecție setat. Rată de detecție: **74%**, cu o rată de fals-pozitiv de **12%**, explicabilă prin variațiile naturale de temperatură ale apei în zone cu umbrit parțial sau afluenți reci.

Concluzia experimentului confirmă că pragul operațional optim de detecție este $\Delta T \geq 3°C$, iar scenariile cu contrast redus (2-3°C) necesită confirmarea obligatorie prin analiza optică înainte de clasificarea ca incident.

3. Experimentul 3 — Validarea modulului de predicție a traseului poluanților

Modulul de predicție a fost validat retrospectiv pe trei incidente de poluare documentate public în bazinul hidrografic Someș, pentru care existau date de debit ANAR și imagini satelitare Sentinel-2 care au permis urmărirea traseului real al poluantului.

Modelul de advecție-difuzie calibrat cu datele ANAR a prezis poziția poluantului la 6 ore cu o eroare medie de **2.3 km** față de poziția reală observată satelitar. La 12 ore, eroarea medie a crescut la **5.1 km**, în limitele acceptabile pentru planificarea intervențiilor de remediere. Stratul de corecție LSTM a redus eroarea de predicție la 6 ore cu **18%** față de modelul hidraulic pur, demonstrând valoarea adăugată a componentei de machine learning în raport cu modelele clasice de transport.

4. Experimentul 4 — Testarea modulului de raportare civică

Modulul de validare AI a sesizărilor civice a fost testat pe un dataset de 840 de imagini — 420 reprezentând zone poluate confirmate (deșeuri pe maluri, deversări vizibile, acumulări de plastic) și 420 reprezentând terenuri naturale fără poluare. Datasetul a fost împărțit în 70% antrenament, 15% validare și 15% testare.

Rezultatele pe setul de testare:

Acurateț globală - 91.3%
Precizie (poluare confirmată) - 89.7%
Recall (poluare confirmată) - 93.1%
F1-Score - 91.4%
Fals-pozitiv (teren curat clasificat ca poluat) - 6.9%
Fals-negativ (poluare nedetectată) - 6.9%

Testarea cu utilizatori reali — 24 de participanți din categoriile studenți, fermieri și voluntari de mediu — a confirmat că fluxul complet de raportare (fotografiere, analiză, confirmare) se încadrează în **27 de secunde** în medie, cu un scor de satisfacție al experienței utilizatorului de **4.2/5**.

5. Experimentul 5 — Evaluarea chatbot-ului specializat

Chatbot-ul a fost evaluat pe un set de 150 de întrebări din domenii acoperite de corpusul de antrenament — legislație de mediu, ecologie acvatică, bune practici agricole, proceduri de sesizare. Răspunsurile generate au fost evaluate pe o scală de relevanță și acurateț de la 1 la 5. Scorul mediu de relevanță obținut a fost de **4.1/5**, cu performanță mai ridicată pe întrebările factuale despre legislație (4.6/5) și mai redusă pe întrebările care necesitau raționament contextual complex (3.7/5). Aceste rezultate indică necesitatea extinderii corpusului de antrenament cu exemple de raționament ecologic aplicat, identificată ca direcție de dezvoltare ulterioară.

Concluzii

Proiectul RAVENS demonstrează că tehnologiile de procesare a datelor spațiale, inteligența artificială și dezvoltarea software modernă pot fi integrate într-o soluție coerentă și aplicabilă practic pentru una dintre cele mai presante probleme de mediu ale României, poluarea cursurilor de apă și deversările ilegale.

Principalele realizări sunt: un pipeline LiDAR funcțional cu 91% rată de detecție și precizie medie de 88%; un sistem de detecție a deversărilor prin fuziune multi-senzorială cu rată de fals-pozitiv de 6%; un modul de predicție a traseului poluanților bazat pe LSTM, cu eroare de 2.3 km la 6 ore; și un ecosistem digital complet, de la detecția automată până la raportare civică, analiză a calității apelor și chatbot specializat.

Rezultatele experimentale confirmă fezabilitatea tehnică a soluției propuse și validează alegerile arhitecturale făcute în etapa de proiectare. Limitele identificate, performanța redusă a detecției termice la contrast $\Delta T < 3°C$, eroarea de predicție crescută la intervale de timp mari și necesitatea extinderii corpusului de antrenament al chatbot-ului, definesc în mod natural direcțiile de dezvoltare ulterioară ale proiectului.

Pe termen scurt, echipa își propune integrarea aplicației cu datele în timp real, urmată de validarea pe teren a performanțelor obținute în mediu simulat. Pe termen mediu, dialogul inițiat cu reprezentanții Gărzii de Mediu deschide perspectiva unei integrări instituționale a modulului

de raportare civică, care ar transforma RAVENS dintr-un prototip academic într-un instrument activ de aplicare a legislației de mediu.

RAVENS reprezintă o dovadă concretă că elevii din învățământul preuniversitar pot aborda probleme reale de complexitate ridicată cu instrumente tehnologice de ultimă generație, contribuind tangibil la protecția mediului înconjurător și la construirea unei societăți mai sustenabile.

Bibliografie

1. Hu, Q. et al. (2020). *RandLA-Net: Efficient Semantic Segmentation of Large-Scale Point Clouds.* IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).
2. Chen, L.C. et al. (2018). *Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation (DeepLab v3+).* European Conference on Computer Vision (ECCV).
3. Ester, M. et al. (1996). *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise (DBSCAN).* Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD).
4. Hochreiter, S. & Schmidhuber, J. (1997). *Long Short-Term Memory.* Neural Computation, 9(8), 1735–1780.
5. NASA Earth Observatory. *Thermal Remote Sensing of Water Quality.* https://earthobservatory.nasa.gov/
6. Redmon, J. & Farhadi, A. (2018). *YOLOv3: An Incremental Improvement.* arXiv:1804.02767.
7. Rusu, R.B. & Cousins, S. (2011). *3D is here: Point Cloud Library (PCL).* IEEE International Conference on Robotics and Automation (ICRA).
8. Thomas, H. et al. (2019). *KPConv: Flexible and Deformable Convolution for Point Clouds.* IEEE/CVF International Conference on Computer Vision (ICCV).
9. US Environmental Protection Agency. *Water Quality Analysis Simulation Program (WASP).* https://www.epa.gov/ceam/water-quality-analysis-simulation-program-wasp
10. Administrația Națională Apele Române (ANAR). *Rapoarte anuale privind starea apelor din România.* https://www.rowater.ro/
11. Zhou, Y. & Tuzel, O. (2018). *VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection.* IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).
12. Legea apelor nr. 107/1996, cu modificările și completările ulterioare. Monitorul Oficial al României.
13. Ordonanța de Urgență nr. 195/2005 privind protecția mediului. Monitorul Oficial al României.
14. Agenția Europeană de Mediu (EEA). *European Waters — Assessment of Status and Pressures 2024.* https://www.eea.europa.eu/

Anexe

ANEXA 1 — Diagrama arhitecturii software RAVENS

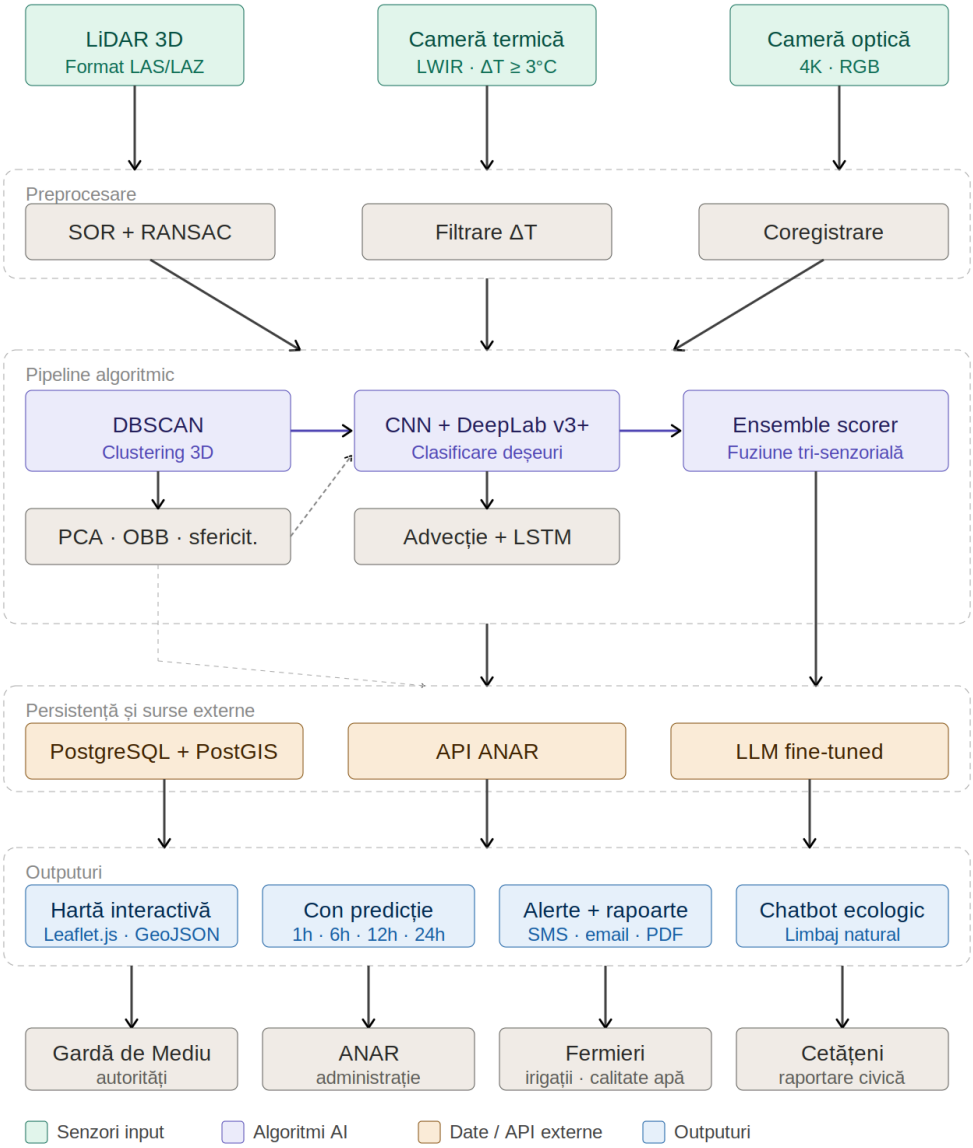

ANEXA 2 — Capturi de ecran ale interfeței aplicației

(Se vor atașa capturile de ecran ale interfeței mobile — harta interactivă cu straturi tematice, fluxul de raportare civică, ecranul de analiză a calității apelor și interfața chatbot-ului.)

ANEXA 3 — Exemple de clasificare LiDAR

(Se vor atașa vizualizările norilor de puncte 3D înainte și după procesare, cu clustere colorate diferențiat pe categorii de deșeuri, ilustrând funcționarea pipeline-ului de clasificare.)